به نام خدا

الگوریتم k نزدیکترین همسایه

فاطمه دلدار- مليحه رضايي

الگوریتم k نزدیکترین همسایه

الگوریتم k نزدیکترین همسایه یک الگوریتم تعلیم با سرپرستی است. در حالت كلي از اين الگوريتم به دو منظور استفاده ميشود: براي تخمين تابع چگالي توزيع دادههاي تعليم و براي طبقهبندي دادههاي تست بر اساس الگوھاي تعليم.

تخمین چگالي توزیع دادهها با استفاده از الگوریتم Kn نزدیکترین همسایه

براي تخمين (p(x از روي n نمونهي تعليم توسط الگوريتم k نزديکترين همسایه میتوانیم یک سلول به مرکزیت x ایجاد کرده و اجازه دهیم این شعاع این سلول تا حدي گسترش پیدا کند که ۴۸ نمونهي تعلیم را در بر گیرد. این نمونهها kn نزدیکترین همسایههای x هستند.

• در حالت کلي k را به صورت kn در نظر ميگيريم که kn تابعي تعريف شده از n است.

اگر چگالی نقاط تعلیم اطراف x زیاد باشد سلول کوچک میشود و بنابراین نتیجهي به دست آمده نتیجهي بهتري است و در صورتي که چگالي نقاط تعلیم اطراف x کم باشد سلول بزرگ میشود. در حالت کلی چگالی توزیع به ازاي هر نقطهي x توسط رابطهي زير محاسبه ميشود:

$$p_n(\mathbf{x}) = \frac{k_n / n}{V}$$

اگر با رشد kn ،n نیز افزایش پیدا کند ٌبه طوري که با رفتن n به سمت بي-نهایت kn نیز به بینهایت میل کند، آنگاه میتوان مطمئن بود که kn/n یک تخمین خوب از این احتمال است که یک نقطه در یک سلول به حجم ۷۰ قرار بگیرد. بنابراین دو شرط زیر شروط لازم و کافی برای این است که pn(x) در نهایت به p(x) همگرا شود:

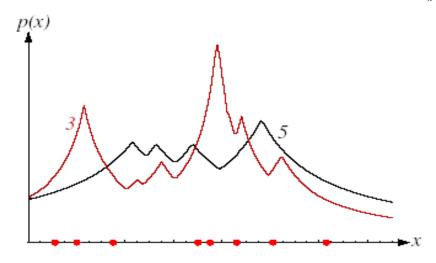
$$\lim_{n\to\infty} k_n = \infty, \quad \lim_{n\to\infty} k_n / n = 0$$

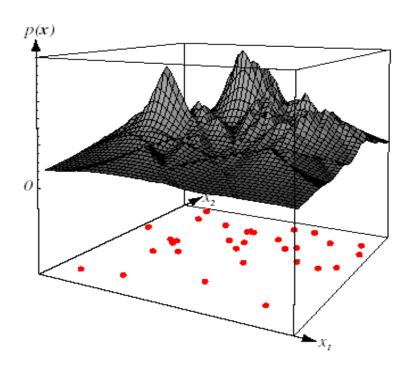
به عنوان مثال اگر kn را √n در نظر بگیریم داریم:

$$k_n = \sqrt{n}$$

 $V_n \approx \frac{1}{\sqrt{p'}}, \quad V_n \approx \frac{V_1}{\sqrt{n'}} \to 0 \text{ as } n \to \infty$ و بنابراین شروط فوق براي k_n داده n داده n داده التحم بينهايت (p(x) به pn(x) ميل ميكند. شكلهاي زير تخميني از تابع چگالي

توزيع نمونههاي داده شده را به ترتيب براي نمونههاي يکبعدي و دوبعدي نشان ميدهند.





تخمین احتمالهای posteriori

روبیک بیان شده در قسمت قبل می تواند برای تخمین احتمالهای posteriori، از یک مجموعه از n نمونه برچسبگذاری شده استفاده شود. ورس از x میکنیم که یک سلول به حجم x حول x رسم کردهایم که یک سلول به حجم x حول x

ورودي را در بر گرفته است و ki تا از اين نمونهها در کلاس wi قرار دارند. بنابراين يک تخمين براي احتمال (p(x,wi به صورت

$$p_n(\mathbf{x}, \omega_i) = \frac{k_i / n}{V}$$
 است و بنابراین داریم:

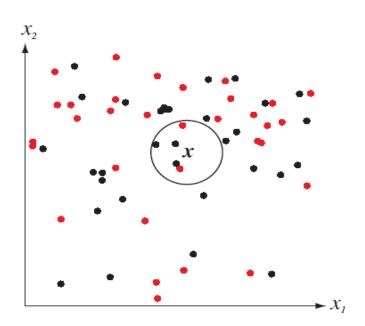
$$p_n(\omega_i \mid \mathbf{x}) = \frac{p_n(\mathbf{x}, \omega_i)}{\sum_{j=1}^c p_n(\mathbf{x}, \omega_j)} = \frac{\frac{k_i / n}{V}}{\sum_{i=1}^c \frac{k_j / n}{V}} = \frac{k_i}{k}$$

يعني براي اينكه نرخ خطا حداقل باشد، نمونهي تست را در دستهاي قرار ميدهيم كه بيشترين تكرار را در سلول داشته باشد. اگر تعداد نمونهها به اندازهي كافي كوچك باشد، اين انتخاب از لحاظ كارايي بهترين انتخاب است.

قانون نزدیکترین همسایه

در تعریف قانون نزدیکترین همسایه k را مساوی یک در نظر گرفته شده است. فرض میکنیم \mathbf{x}_n \mathbf{x}_n مجموعهای از n الگوی ورودی باشد و است. فرض میکنیم \mathbf{x}_n ورودی به نقطه تست x باشد. قانون نزدیکترین $\mathbf{x}' \in D'$ همسایه برای طبقه بندی \mathbf{x}' آن را در کلاسی مشابه با کلاس \mathbf{x}' قرار میدهد. قانون نزدیکترین همسایه یک روال sub-optimal است یعنی نرخ خطای آن معمولاً بیشتر از حداقل نرخ خطای ممکن یعنی نرخ خطای الگوریتم بیز است. ولی ثابت میشود که در صورت استفاده از تعداد نامحدودی از الگوهای ورودی نرخ خطا در بدترین حالت بیشتر از دو برابر نرخ خطای الگوریتم بیز الگوریتم بیز نخواهد شد.

قانون k نزدیکترین همسایه گسترشی از قانون نزدیکترین همسایه است و همانطور که واضح است این قانون x را در دستهای طبقهبندی میکند که بیشترین تکرار را در بین k نزدیکترین همسایهی x دارد. به عنوان مثال در شکل زیر x توسط این قانون در کلاس سیاه قرار میگیرد.



پیچیدگي محاسباتي در الگوریتم نزدیکترین همسایه

براي محاسبهي پيچيدگي الگوريتم k نزديکترين همسايه فرض ميکنيم که انمونهي تعليم b بعدي داريم و ميخواهيم نزديکترين آنها به نقطهي تست (k=1) x (l) را به دست آوريم. در سادهترين روش براي هر نقطهي تعليم فاصلهي آن تا نقطهي تست را محاسبه کرده و نزديکترين آنها به نقطه تست را برميگردانيم. محاسبهي فاصلهي اقليدس براي هر نقطه در (0(d) انجام مي-شود و چون n نقطهي تعليم ذخيره شده داريم اين محاسبه (O(nd) زمان مي-برد و در نهايت انتخاب کوتاهترين فاصله نيز در زمان (n(l) انجام ميشود.

سه تكنيك الگوريتمي براي كاهش پيچيدگي محاسباتي الگوريتم نزديكترين همسايه وجود دارد:

- محاسبهي فاصلههاي جزئي
 - Prestructuring •
- ويرايش الگوهاي ذخيره شده

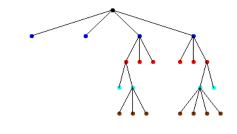
محاسبه فاصلهها جزئي: در اين روش فاصله بين دو نقطه را ابتدا به صورت كامل محاسبه نميكنيم بلكه آن را به صورت تدريجي و با افزودن ابعاد محاسبه ميكنيم. اگر فضا را d بعدي در نظر بگيريم، فاصله جزئي بر مبناي r بعد انتخاب شده از اين d بعد به صورت زير محاسبه ميشود:

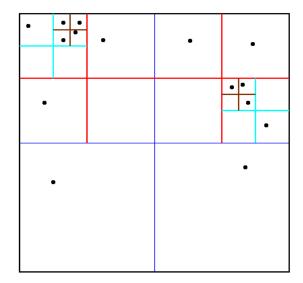
$$D_r(\mathbf{a}, \mathbf{b}) = \left(\sum_{k=1}^r (a_k - b_k)^2\right)^{1/2}, \quad r < d$$

ميتوانيم محاسبهي فاصلهي جزئي را تا زماني ادامه دهيم كه بزرگتر از فاصلهي فعلي نقطهي تست از نزديکترين الگوي فعلي شود. در اين حالت مطمئن ميشويم كه اين الگو نزديكترين الگو به نقطهي تست مورد نظر نيست و محاسبهي فاصله را متوقف ميكنيم.

Prestructuring: در این روش بر روي الگوهاي تعلیم مورد جستجو شکلي از درخت جستجو را ایجاد ميکنیم. در حین فرآیند طبقهبندي کردن فقط فاصله- ي نقطهي تست را تا یک یا تعداد کمي از الگوهاي ذخیره شده در درخت محاسبه ميکنیم. به این معني که یک الگو که نزدیکتر از بقیهي الگوها به نقطهي تست به نظر ميرسد را انتخاب کرده و به صورت بازگشتي فقط الگوهاي متصل به آن را در درخت جستجو ميکنيم. اگر درخت به درستي ساخته شده باشد تعداد کل الگوهاي موردنیاز براي جستجو کاهش پیدا ميکند.

یکی از این ساختارهای درختی QuadTree است. در این درخت هر نود میانی چهار فرزند دارد. این درخت اغلب به این منظور استفاده میشود که فضاهای دوبعدی را به صورت بازگشتی به چهار ناحیه تقسیم کند. این نواحی میتوانند مربع، مستطیل یا هر شکل دلخواه دیگری داشته باشد. شکل زیر ساخته شدن یک QuadTree را نشان میدهد.





این روش به هیچ عنوان تضمین نمیکند که نزدیکترین الگو را پیدا کند. در جستجوی الگوهای تعلیم از طریق این درخت در هر مرحله 3 فضای جستجو حذف میشود و فقط 4 ای باقی میماند که فاصله ینقطه ی تست تا مرکز آن ناحیه کمتر از سه ناحیه ی دیگر است. بنابراین ممکن است نزدیکترن الگو به نقطه ی تست در یکی از نواحی دیگر قرار داشته باشد (این مشکل بیشتر در مواقعی پیش میآید که نقطه ی تست نزدیک به مرز ناحیه قرار دارد) و بنابراین با حذف آن ناحیه نزدیکترین الگو به نقطه ی تست را نیز از دست

بدهيم. با وجود اينكه اين روش روش تضمينشدهاي نيست ولي براي كاهش فضاي جستجو روش مناسبي است.

ويرايش الگوهاي ذخيرهشده: روش سوم براي كاهش پيچيدگي جستجوي نزديكترين همسايه حذف الگوهاي غيرمفيد در حين تعليم است. يک روش براي كاهش پيچيدگي فضايي (O(n) اين است كه الگوهايي كه همهي نقاط تعليم اطراف آنها در كلاسي مشابه با خود الگو قرار دارند را حذف كنيم. با اين كار مرزهاي تعليم تغيير نميكند در حالي كه فضاي جستجو كاهش پيدا ميكند. يک الگوريتم ساده براي اين كار به صورت زير است:

Algorithm. (Nearest-Neighbor Editing)

- 1. **begin initialize** $j \leftarrow 0$, $D \leftarrow$ data set, $n \leftarrow \#$ prototypes
- *2.* construct the full Voronoi diagram of *D*
- 3. **do** $j \leftarrow j + 1$; for each prototype **x**'j
- 4. find the Voronoi neighbors of **x**′j
- 5. if any neighbor is not from the same class as , **then** mark **x**′j
- 6. $\frac{\mathbf{until}}{\mathbf{j}} \mathbf{j} = \mathbf{n}$
- 7. discard all points that are not marked
- construct the Voronoi diagram of the remaining (marked) prototypes
- 9. <u>end</u>

از آنجايي كه الگوهايي كه در مرز تصميم قرار دارند حداقل يكي از همسايه-هايشان از دستهاي متفاوت هستند، بنابراين با اجراي الگوريتم بالا حذف نميشوند و مرز تصميم تغييري پيدا نميكند. اين الگوريتم تضمين نميدهد كه حداقل مجموعه الگوهاي تعليم مفيد باقي بمانند. يكي از مشكلات چنين سيستم نزديكترين همسايهاي اين است كه نميتوان بعدا الگوي تعليمي به اين الگوها اضافه كرد چون براي اجراي اين الگوريتم نياز است كه همهي الگوهاي تعليم وجود داشته باشند.

ميتوان اين سه روش كاهش پيچيدگي را با هم ادغام كرد، يعني ابتدا الگوها را ويرايش كرد، بعد بر روي الگوهاي باقيمانده يك درخت جستجو ايجاد كرد و در نهايت در هنگام انجام عمل طبقهبندي فاصلههاي جزئي را محاسبه كرد.

پيادهسازي الگوريتم k نزديكترين همسايه

در پیادهسازی الگوریتم k نزدیکترین همسایه در نرمافزار مطلب کلاسهای زیر به کار رفته است:

کلاس CalDistance.m

این کلاس فاصله یبین همه ی نقاط تعلیم از همه ی نقاط تست را بر اساس یکی از معیارهای فاصله محاسبه کرده و ماتریس فاصلهها را برمیگرداند. ورودی این کلاس train(نقاط تعلیم)، test(نقاط تست) و distance) معیار فاصله ی موردنظر) است که این معیار فاصله می تواند یکی از موارد زیر باشد:

- euclidean: فاصلهي اقليدس
- cityblock: مجموع قدرمطلق فاصلهها
- cosine: یک منهای کسینوس زاویه ی محصور بین دو نقطه (نقاط را به عنوان بردار در نظر میگیریم)
 - correlation: یک منهای کوررولیشن بین دو نقطه
- hamming: این فاصله فقط براي دادههاي باینري مناسب است و درصدي از بیتها را که با هم متفاوت هستند نشان ميدهد.

کلاس KNNClassification.m

این کلاس کلاس اصلی برنامه میباشد و k نزدیکترین همسایه به هر یک از نقاط تست را محاسبه کرده و بر اساس آنها مشخص میکند که هر یک از نقاط تست در چه دسته یا کلاسی قرار میگیرند.

وروديهاي اين كلاس train(نقاط تعليم)، test(نقاط تست)، group(ماتريسي ستوني كه تعداد سطرهاي آن مساوي با تعداد سطرهاي است و مشخص ميكند كه هر يك از الگوهاي تعليم در چه كلاسي قرار ميگيرند)، لا كه تعداد نزديكترين همسايه مورد نظر براي الگوريتم KNN را مشخص ميكند، dist كه معيار فاصلهي مورد نظر براي محاسبهي فاصلهي بين نقاط تعليم و نقاط تست را بيان ميكند و rule كه ميتواند يكي از موارد زير باشد:

consensus وقتي اين گزينه به عنوان الاديكترين شود به اين معني است فقط در صورتي كه همهي لا نزديكترين همسايهي يك نقطهي تست به يك كلاس مشابه تعلق داشته باشند آن نقطهي تست نيز در همان كلاس طبقهبندي ميشود ولي اگر حتي يكي از نقاط لا نزديكترين همسايهي يك نقطهي تست در كلاسي متفاوت با بقيه قرار داشته باشد، آن نقطهي تست قابل طبقهبندي با اين الگوريتم نيست. در ساير موارد به غير از مواقعي كه اين گزينه به عنوان الاوريتم قرار ميگيرد از قانون اكثريت استفاده ميشود يعني يك نقطهي تست در كلاسي قرار ميگيرد كه تعداد نقاطي از لا نزديكترين همسايهي آن كه در آن كلاس قرار دارند نسبت به ساير كلاسها بيشتر باشد. در مواقعي كه گره ايجاد ميشود يعني بيشتر نقاط در يك كلاس الله قرار گرفته در بيش از يك كلاس با هم برابر هستند از يكي از سه قانون زير براي شكستن اين گره استفاده ميشود:

- nearest: یعنی از بین گروههای به هم گره خورده کلاس نزدیکترین همسایه به عنوان کلاس خروجی انتخاب میشود.
- farthest: یعنی از بین گروههای به هم گره خورده کلاس دورترین
 همسایه به عنوان کلاس خروجی انتخاب میشود.
- random: یعني براي شکستن گره به صورت تصادفي یکي از همسایه-هایي که به هم گره خوردهاند انتخاب شده و کلاس آن همسایه به عنوان کلاس خروجي برگردانده ميشود.

در کلاس KNNClassification، ابتدا توسط تابع CalDistance فاصله بین نقاط تعلیم و تست محاسبه شده و در ماتریس b قرار میگیرد. سپس این ماتریس را مرتب میکنیم یعنی برای هر نقطه ی تست نقاط تعلیم را به صورت صعودی بر حسب فاصله از آن نقطه ی تست در سطر مربوط به آن قرار داده و سپس b نقطه ی تعلیم اول هر یک از این سطرها را به عنوان k نزدیکترین همسایه ی هر یک از نقاط تست جدا میکنیم. پس از آن در یک حلقه به ازای هر یک از نقاط تست محاسبه میکنیم که هر یک از b نزدیکترین همسایه ی آن در چه کلاسی قرار دارند و کلاسی که ماکزیمم تعداد همسایه ها در آن قرار دارند را به عنوان کلاس خروجی انتخاب می- کنیم. در صورت به وجود آمدن گره نیز با توجه به نوع rule گره را باز میکنیم.

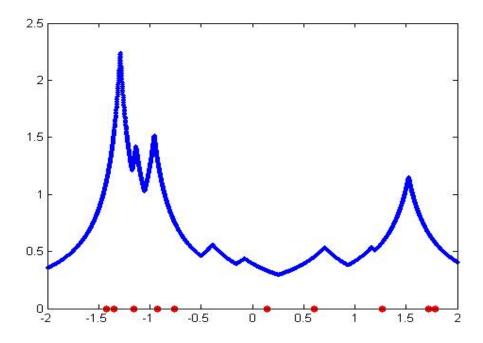
کلاس classification.m

این کلاس کلاس اجرایي برنامه است که در آن الگوهاي تعلیم و گروههاي آنها، الگوهاي تست، مقدار k، معیار فاصله و rule را انتخاب کرده و با توجه به آنها کلاس KNNClassification را فراخواني ميکنيم.

کلاس KNN1.m

این کلاس برای تخمین تابع چگالی توزیع نقاط تعلیم با توجه به الگوریتم ۸ نزدیکترین همسایه استفاده میشود. به این منظور نقاط تست را از ابتدا تا انتهای بازهای که نقاط تعلیم در آن قرار دارند با فاصلهی کم از هم در نظر گرفته و برای هر کدام از آنها تابع CalDistance را فراخوانی میکنیم تا فاصلهی آن از تمام نقاط تعلیم را به دست آوریم. سپس این فاصلهها را مرتب میکنیم. از آنجایی که در استفاده از الگوریتم ۸ نزدیکترین همسایه برای تخمین چگالی توزیع الگوهای ورودی در نقطهی x به مرکزیت آن نقطه سلولی ایجاد میکنیم و اجازه میدهیم شعاع این سلول تا حدی گسترش پیدا کند که k میکنیم و اجازه میدهیم شعاع این سلول تا حدی گسترش پیدا کند که k منزدیکترین همسایهی نقطهی x را در بر گیرد، بنابراین در لیست مرتب شده انزدیکترین همسایه ی نقطه ی در نظر میگیریم و در نهایت با استفاده از رابطهی p=k/n.v میآوریم. در کلاس KNN۱ دادهها به صورت یک بعدی در نظر گرفته شدهاند و بنابراین به جای ۷ طول خط یا همان k را در نظر میگیریم. در شکل زیر نمونهای از

خروجي اين كلاس نشان داده شده است. (الگوهاي ورودي با نقاط قرمز مشخص شدهاند)



کلاس KNN2.m

این کلاًس کاملاً مشابه کلاس KNN۱ است با این تفاوت که در این کلاس دادهها به صورت دو بعدی در نظر گرفته شدهاند و به همین دلیل به جای ۷ مساحت دایرهی به مرکزیت x و شعاع k را محاسبه میکنیم. در شکل زیر نمونهای از خروجی این کلاس آمده است.

